Tutorial: From Data to Model Pipeline with Machine Learning

Super AI Engineer Season 6 LV1: Zero to Hero

Norapat Buppodom - AI Engineer, Metier (Thailand)

Tabular Dataset

PassengerId	Survived	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked
1	0	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.25		S
2	1	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C
3	1	3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101282	7.925		S
4	1	1	Futrelle, Mrs. Jacques Heath (Lily May Peel)	female	35	1	0	113803	53.1	C123	S
5	0	3	Allen, Mr. William Henry	male	35	0	0	373450	8.05		S
6	0	3	Moran, Mr. James	male		0	0	330877	8.4583		Q
7	0	1	McCarthy, Mr. Timothy J	male	54	0	0	17463	51.8625	E46	S
8	0	3	Palsson, Master. Gosta Leonard	male	2	3	1	349909	21.075		S
9	1	3	Johnson, Mrs. Oscar W (Elisabeth Vilhelmina Berg)	female	27	0	2	347742	11.1333		S
10	1	2	Nasser, Mrs. Nicholas (Adele Achem)	female	14	1	0	237736	30.0708		C
11	1	3	Sandstrom, Miss. Marguerite Rut	female	4	1	1	PP 9549	16.7	G6	S
12	1	1	Bonnell, Miss. Elizabeth	female	58	0	0	113783	26.55	C103	S
13	0	3	Saundercock, Mr. William Henry	male	20	0	0	A/5. 2151	8.05		S
14	0	3	Andersson, Mr. Anders Johan	male	39	1	5	347082	31.275		S
15	0	3	Vestrom, Miss. Hulda Amanda Adolfina	female	14	0	0	350406	7.8542		S
16	1	2	Hewlett, Mrs. (Mary D Kingcome)	female	55	0	0	248706	16		S
17	0	3	Rice, Master. Eugene	male	2	4	1	382652	29.125		Q
18	1	2	Williams, Mr. Charles Eugene	male		0	0	244373	13		S
19	0	3	Vander Planke, Mrs. Julius (Emelia Maria Vandemoortele)	female	31	1	0	345763	18		S
20	1	3	Masselmani, Mrs. Fatima	female		0	0	2649	7.225		C
21	0	2	Fynney, Mr. Joseph J	male	35	0	0	239865	26		S
22	1	2	Beesley, Mr. Lawrence	male	34	0	0	248698	13	D56	S
23	1	3	McGowan, Miss. Anna "Annie"	female	15	0	0	330923	8.0292		Q
24	1	1	Sloper, Mr. William Thompson	male	28	0	0	113788	35.5	A6	S
25	0	3	Palsson, Miss. Torborg Danira	female	8	3	1	349909	21.075		S
26	1	3	Asplund, Mrs. Carl Oscar (Selma Augusta Emilia Johansson)	female	38	1	5	347077	31.3875		S
27	0	3	Emir, Mr. Farred Chehab	male		0	0	2631	7.225		C
28	0	1	Fortune, Mr. Charles Alexander	male	19	3	2	19950	263	C23 C25 C27	S
29	1	3	O'Dwyer, Miss. Ellen "Nellie"	female		0	0	330959	7.8792		Q
30	0	3	Todoroff, Mr. Lalio	male		0	0	349216	7.8958		S

PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
1	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.25		S	0
2	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C	1
3	3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101	7.925		S	1

- สีน้ำเงิน = ID
- สีเหลือง = Features
- สีเขียว = Label

“Garbage in Garbage out”

“เราจะใช้ ID ในการอ้างอิง Example เท่านั้น ไม่เอาไปเทรนโมเดลเด็ดขาด”

Features (Function)-> Label

“โมเดล Machine Learning ที่เราจะทำกับนี่แหล่ะคือ Function”

(Function)->

“Ai จะเก่งได้ต้องมีตัวอย่างให้เค้าเรียนก่อน”

50+ Examples

Train

→

1+ Examples

Test

“เอาไปใช้จริง

Train

Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.25		S	0
1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C	1
3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101	7.925		S	1

Test

“Test จะไม่มี Label”

Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
2	Montvila, Rev. Juozas	male	27	0	0	211536	13		S	
1	Graham, Miss. Margaret Edith	female	19	0	0	112053	30	B42	S	
3	Johnston, Miss. Catherine Helen "Carrie"	female		1	2	W./C. 6607	23.45		S	

“ข้อมูล Test ห้ามซ้ำกับ Train”

Data Leakage “จำข้อสอบไปตอบ”

“ต้อง Clean ก่อน”

Missing Feature Data

Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
2	Montvila, Rev. Juozas	male	27	0	0	211536	13		S	
1	Graham, Miss. Margaret Edith	female	19	0	0	112053	30	B42	S	
3	Johnston, Miss. Catherine Helen "Carrie"	female		1	2	W./C. 6607	23.45		S	

สำคัญ: ทั้ง Train และ Test ต้อง process ด้วยวิธีเดียวกัน

Data Processing before Modeling Checklist

- Handling Missing Values ✅
- Remove Outliers ✅
- Feature Scaling ✅
- One-hot encoding ✅
- Selecting Important Information from the data ✅
-

....

“ไปเรียนเพิ่มเติมได้ที่ Lecture ก่อนหน้า”

Core Concept:

“Machine Learning เข้าใจแค่ตัวเลขเท่านั้น”

“ถ้า Feature เราไม่ใช่ตัวเลข ต้องแปลงเป็นตัวเลขก่อน”

Sex
0
1
1

EX.

- male, female → 0, 1
- Cabin class A,B,C → 1,2,3
- ตัวหนังสือที่ไม่ใช่ Category → <u>ขอข้ามไปก่อน</u>

Pclass 1	Pclass 2	Pclass 3
0	1	0
1	0	0
0	0	1

Name
Montvila, Rev. Juozas
Graham, Miss. Margaret Edith
Johnston, Miss. Catherine Helen "Carrie"

“เป็นตัวเลขเหมือนกัน แต่ป้อนเข้าไปโมเดลทำงานไม่เหมือนกันนะ”

Category

Sex
0
1
1

Pclass 1	Pclass 2	Pclass 3
0	1	0
1	0	0
0	0	1

“ไม่ได้มี Scale ชัดเจน”

Numerical

Age
27
19
14

“มี Scale ชัดเจน”

Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
2	Montvila, Rev. Juozas	male	27	0	0	211536	13		S	
1	Graham, Miss. Margaret Edith	female	19	0	0	112053	30	B42	S	
3	Johnston, Miss. Catherine Helen "Carrie"	female		1	2	W./C. 6607	23.45		S	

Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
2	Montvila, Rev. Juozas	0	27	0	0	211536	13	Unknown	S	
1	Graham, Miss. Margaret Edith	1	19	0	0	112053	30	B42	S	
3	Johnston, Miss. Catherine Helen "Carrie"	1	14	1	2	W./C. 6607	23.45	Unknown	S	

“Sex เปลี่ยนเป็นตัวเลข”
“ใส่ค่าเฉลี่ย Age ลงไปในช่องที่ว่าง”

“เพิ่ม Category Unknown ให้ Cabin ที่ไม่มีข้อมูล”

Pclass 1	Pclass 2	Pclass 3	Sex	Age	SibSp	Parch	Fare	Cabin B42	Cabin Unknowr	Embarked S	Embarked J	Survived
0	1	0	0	27	0	0	13	0	1	1	0	
1	0	0	1	19	0	0	30	1	0	1	0	
0	0	1	1	14	1	2	23.45	0	1	1	0	

“แปลงข้อมูล Category ทั้งหมดเป็นตัวเลข 0,1"

ลักษณะของโจทย์ Machine Learning

Classification

"Output เป็น **Category**" ex.

- **ฝนตกมั้ย**
- **ภาคไหนฝนจะตก**

ฝนตก
0
1
0

ฝนตกภาคกลาง	ฝนตกภาคเหนือ	ฝนตกภาคใต้
1	1	0
0	1	0
1	1	0

Regression

"Output เป็น **Number**" ex. **ฝนตกกี่ มม**

ฝนตกกี่ มม
32.2
100.2
10.1

Data ที่ใช้เทรน

50+ Examples

Train

- Clean and Converted ✅
- **Feature Selection****
- **Feature Engineered****

Feature Selection

Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
2	Montvila, Rev. Juozas	male	27	0	0	211536	13		S	
1	Graham, Miss. Margaret Edith	female	19	0	0	112053	30	B42	S	
3	Johnston, Miss. Catherine Helen "Carrie"	female		1	2	W./C. 6607	23.45		S	

Class Example = **10 Features** 🤩

Some Real World Example = **100+ Features** 😱

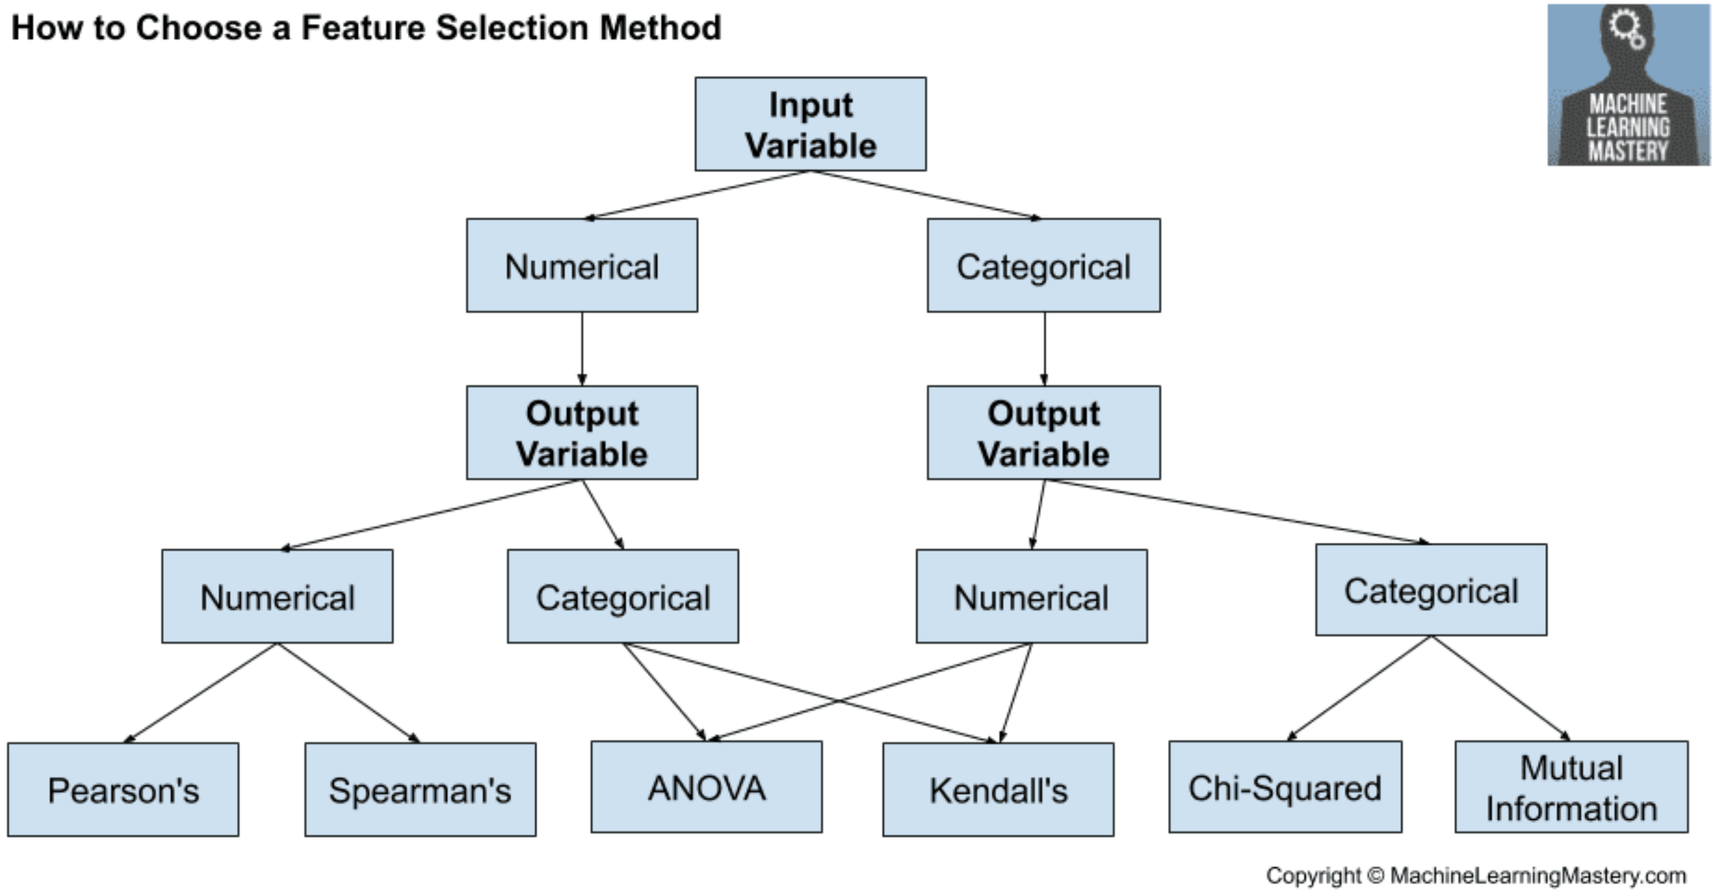

Source: https://machinelearningmastery.com/feature-selection-with-real-and-categorical-data/

Pearson Correlation

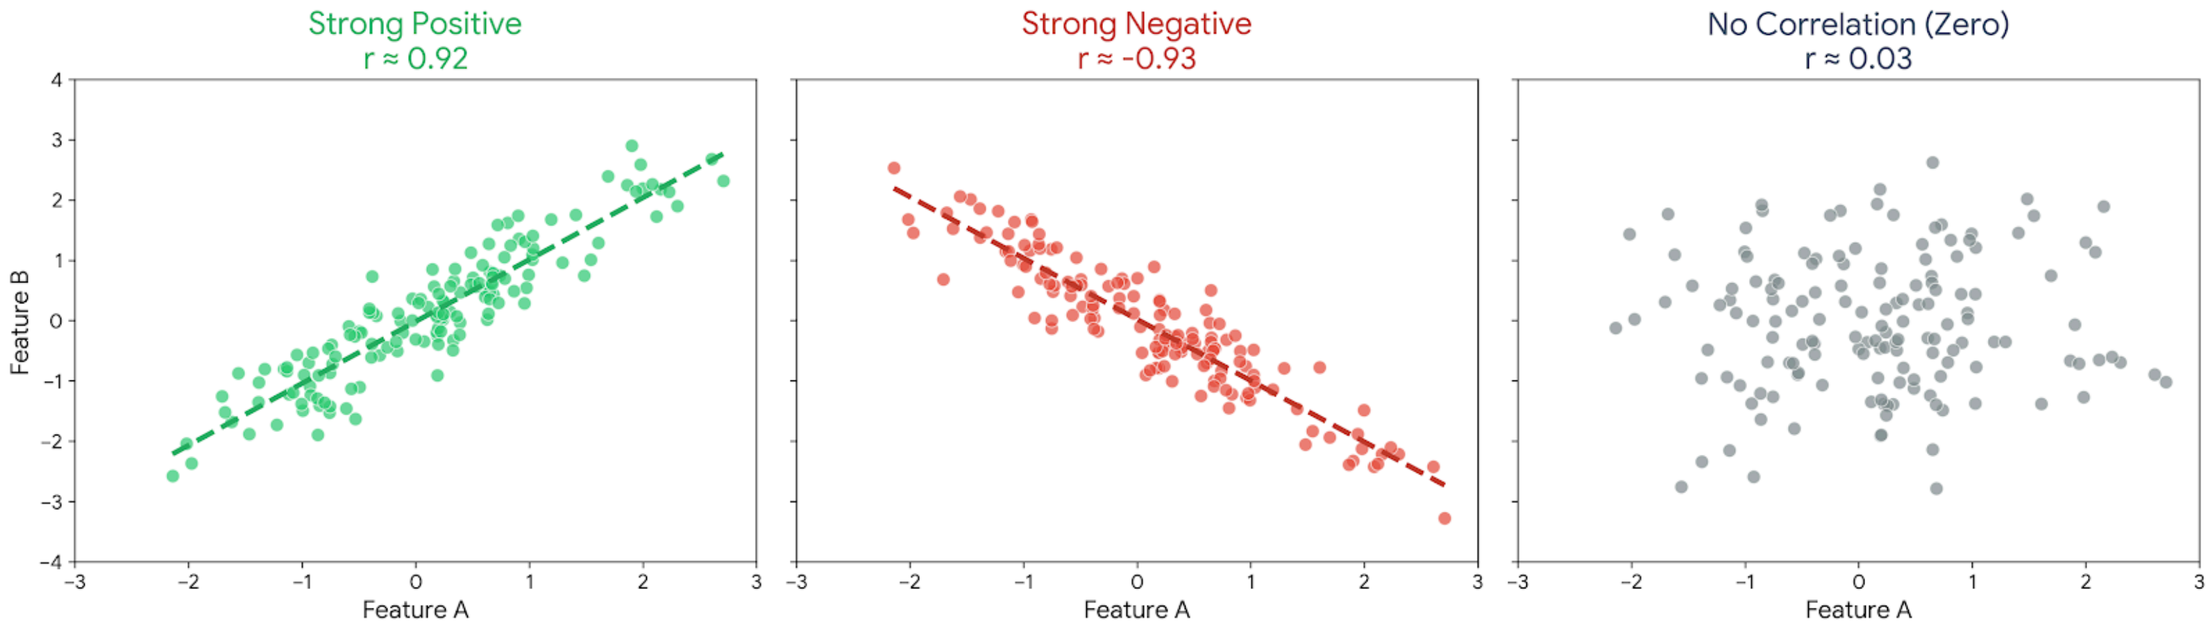

“ใช้ได้ดีกับ linear relathipship เท่านั้น”

Correlation Thresold

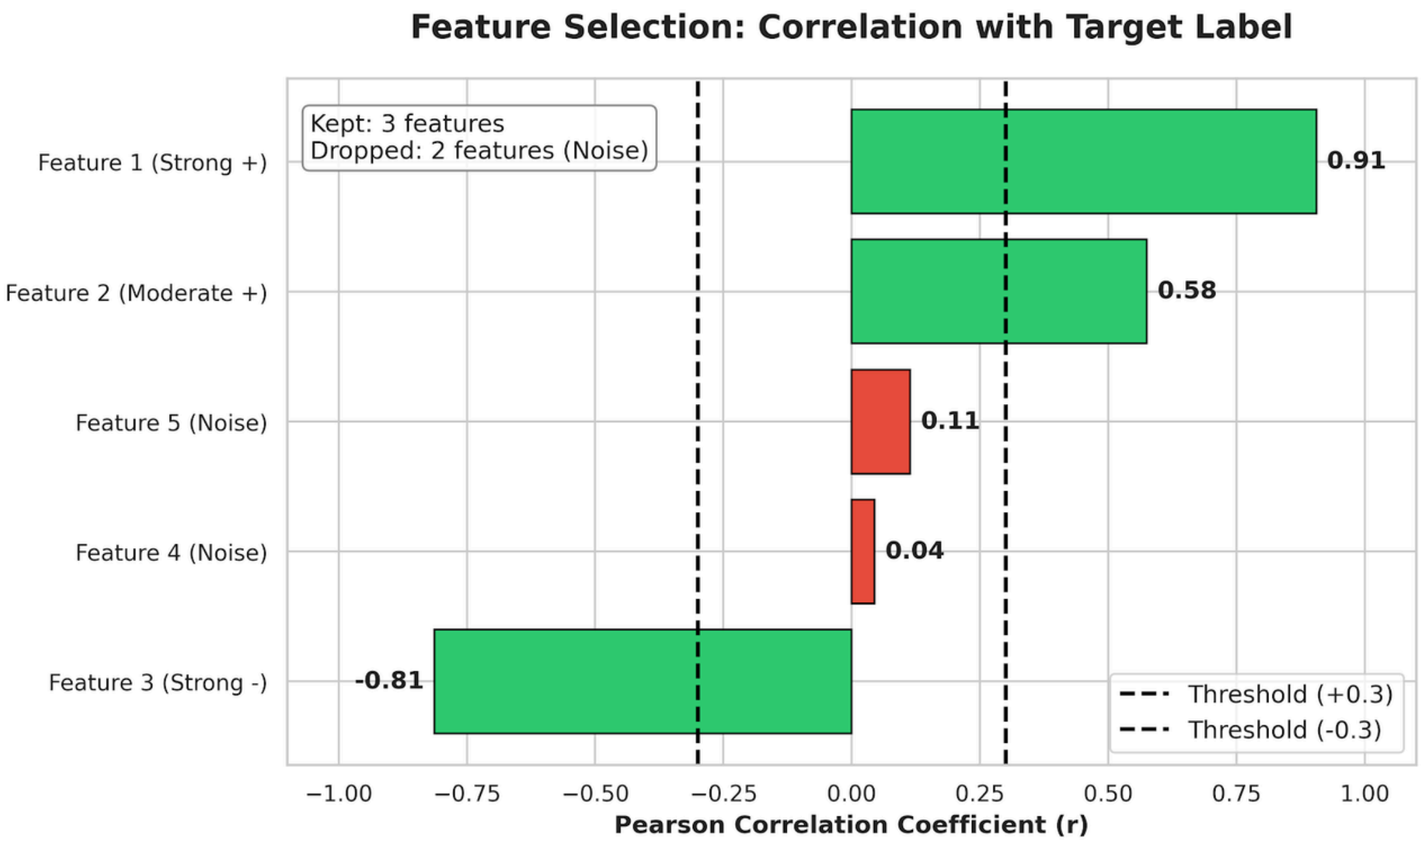

“เอา Feature ที่ไม่วิ่งตาม Label ออก”

Feature Correlation Threshold

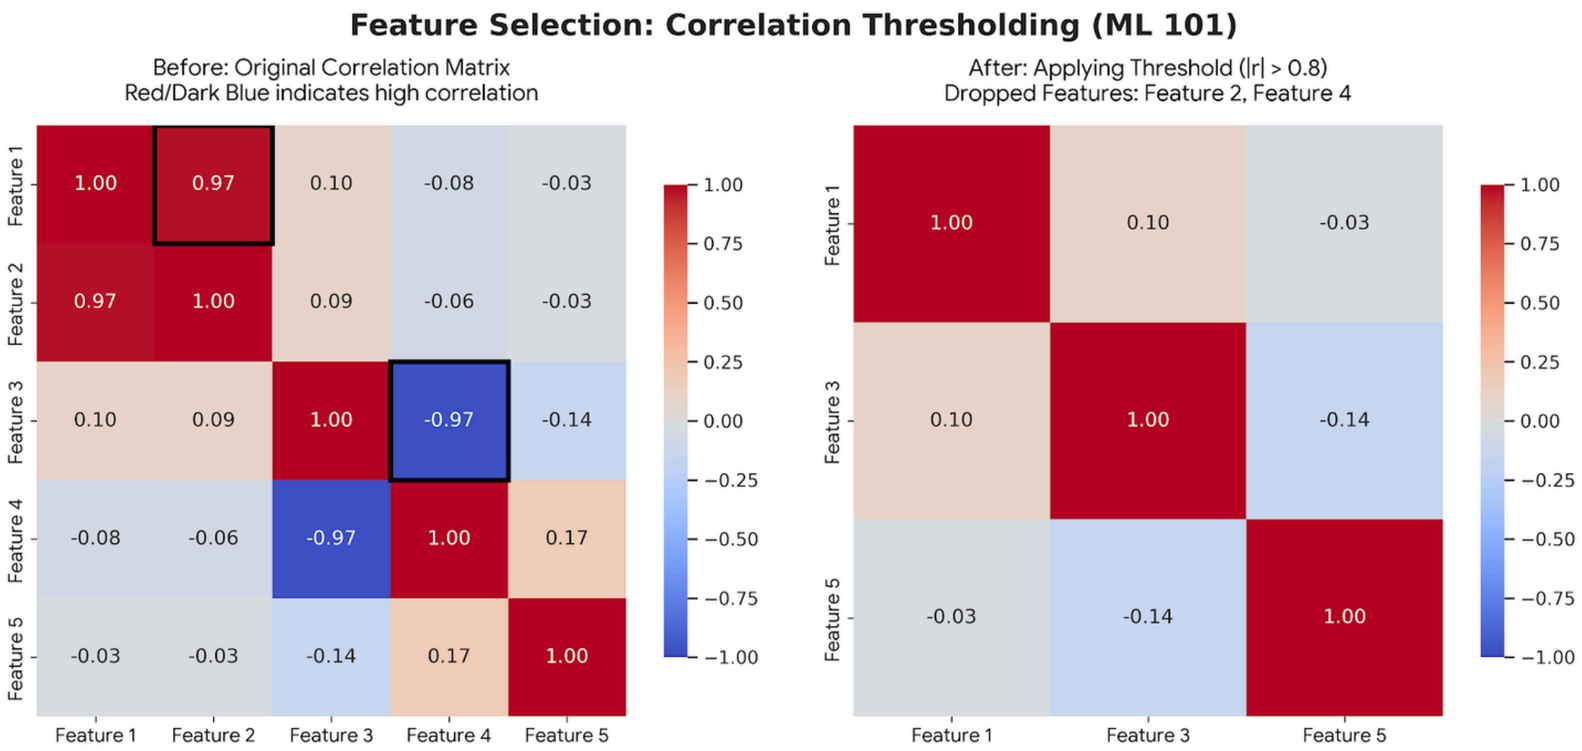

“Feature ที่คล้ายกันเกินไป ยุบเหลือ 1 พอ”

Feature Engineering

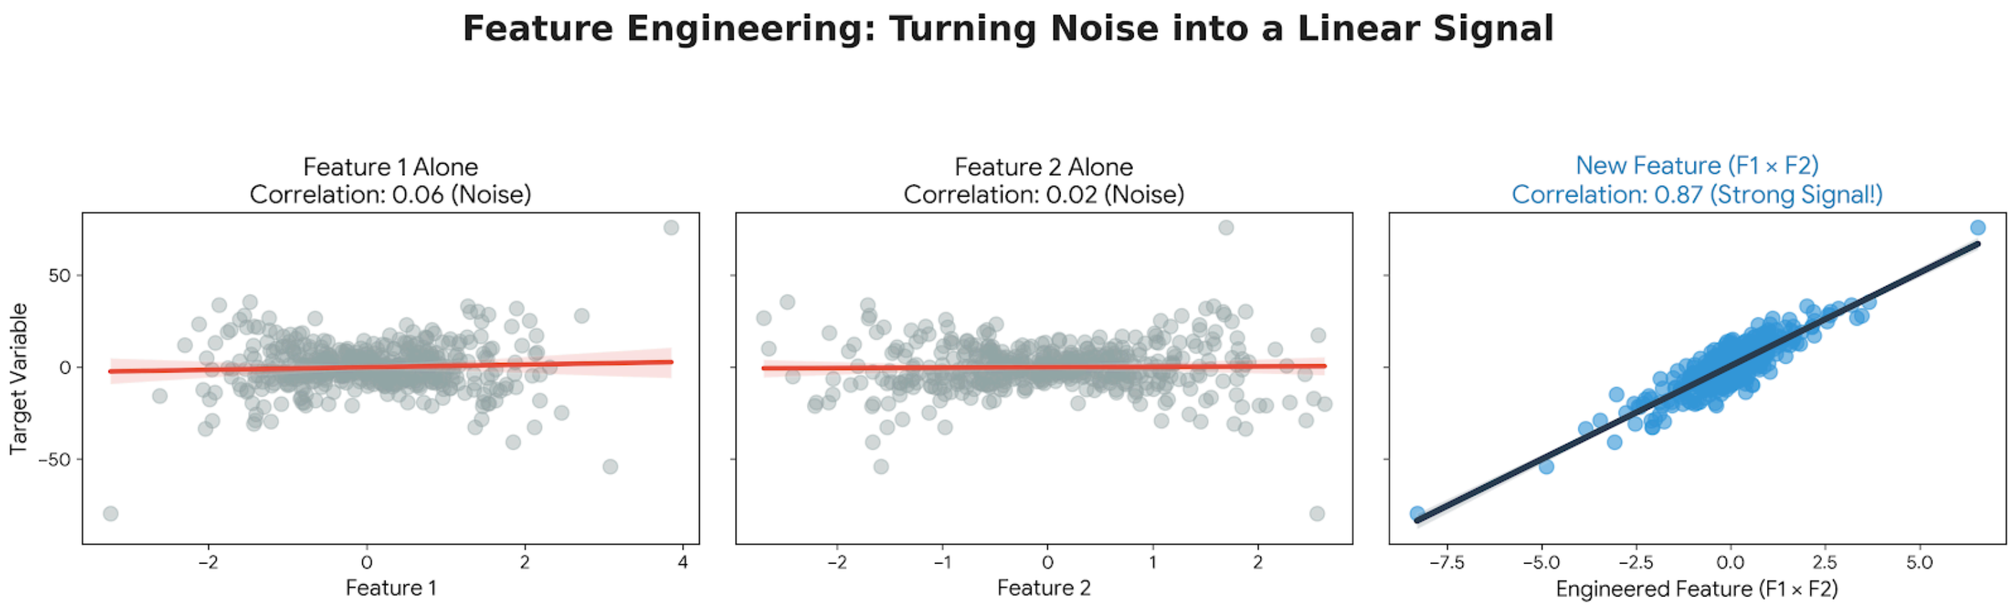

เช่นเอา **Age * Fare ^ 2** = Feature ใหม่

Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.25		S	0
1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C	1
3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101	7.925		S	1

Train

PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
1	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.25		S	0
2	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C	1
3	3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101	7.925		S	1

ปัญหา

- train คะแนนเฟ้อเพราะจำข้อสอบ **“overfit”**
- test ไม่มี label ไปวัดผล

Test

PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
887	2	Montvila, Rev. Juozas	male	27	0	0	211536	13		S	
888	1	Graham, Miss. Margaret Edith	female	19	0	0	112053	30	B42	S	
889	3	Johnston, Miss. Catherine Helen "Carrie"	female		1	2	W./C. 6607	23.45		S	

Train

PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
1	3	Braund, Mr. Owen Harris	male	22	1	0	A/5 21171	7.25		S	0
2	1	Cumings, Mrs. John Bradley (Florence Briggs Thayer)	female	38	1	0	PC 17599	71.2833	C85	C	1
3	3	Heikkinen, Miss. Laina	female	26	0	0	STON/O2. 3101	7.925		S	1

Solution: Validation

PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
21	2	Fynney, Mr. Joseph J	male	35	0	0	239865	26		S	0
22	2	Beesley, Mr. Lawrence	male	34	0	0	248698	13	D56	S	1
23	3	McGowan, Miss. Anna "Annie"	female	15	0	0	330923	8.0292		Q	1

Test

PassengerId	Pclass	Name	Sex	Age	SibSp	Parch	Ticket	Fare	Cabin	Embarked	Survived
887	2	Montvila, Rev. Juozas	male	27	0	0	211536	13		S	
888	1	Graham, Miss. Margaret Edith	female	19	0	0	112053	30	B42	S	
889	3	Johnston, Miss. Catherine Helen "Carrie"	female		1	2	W./C. 6607	23.45		S	

Hackathon Time

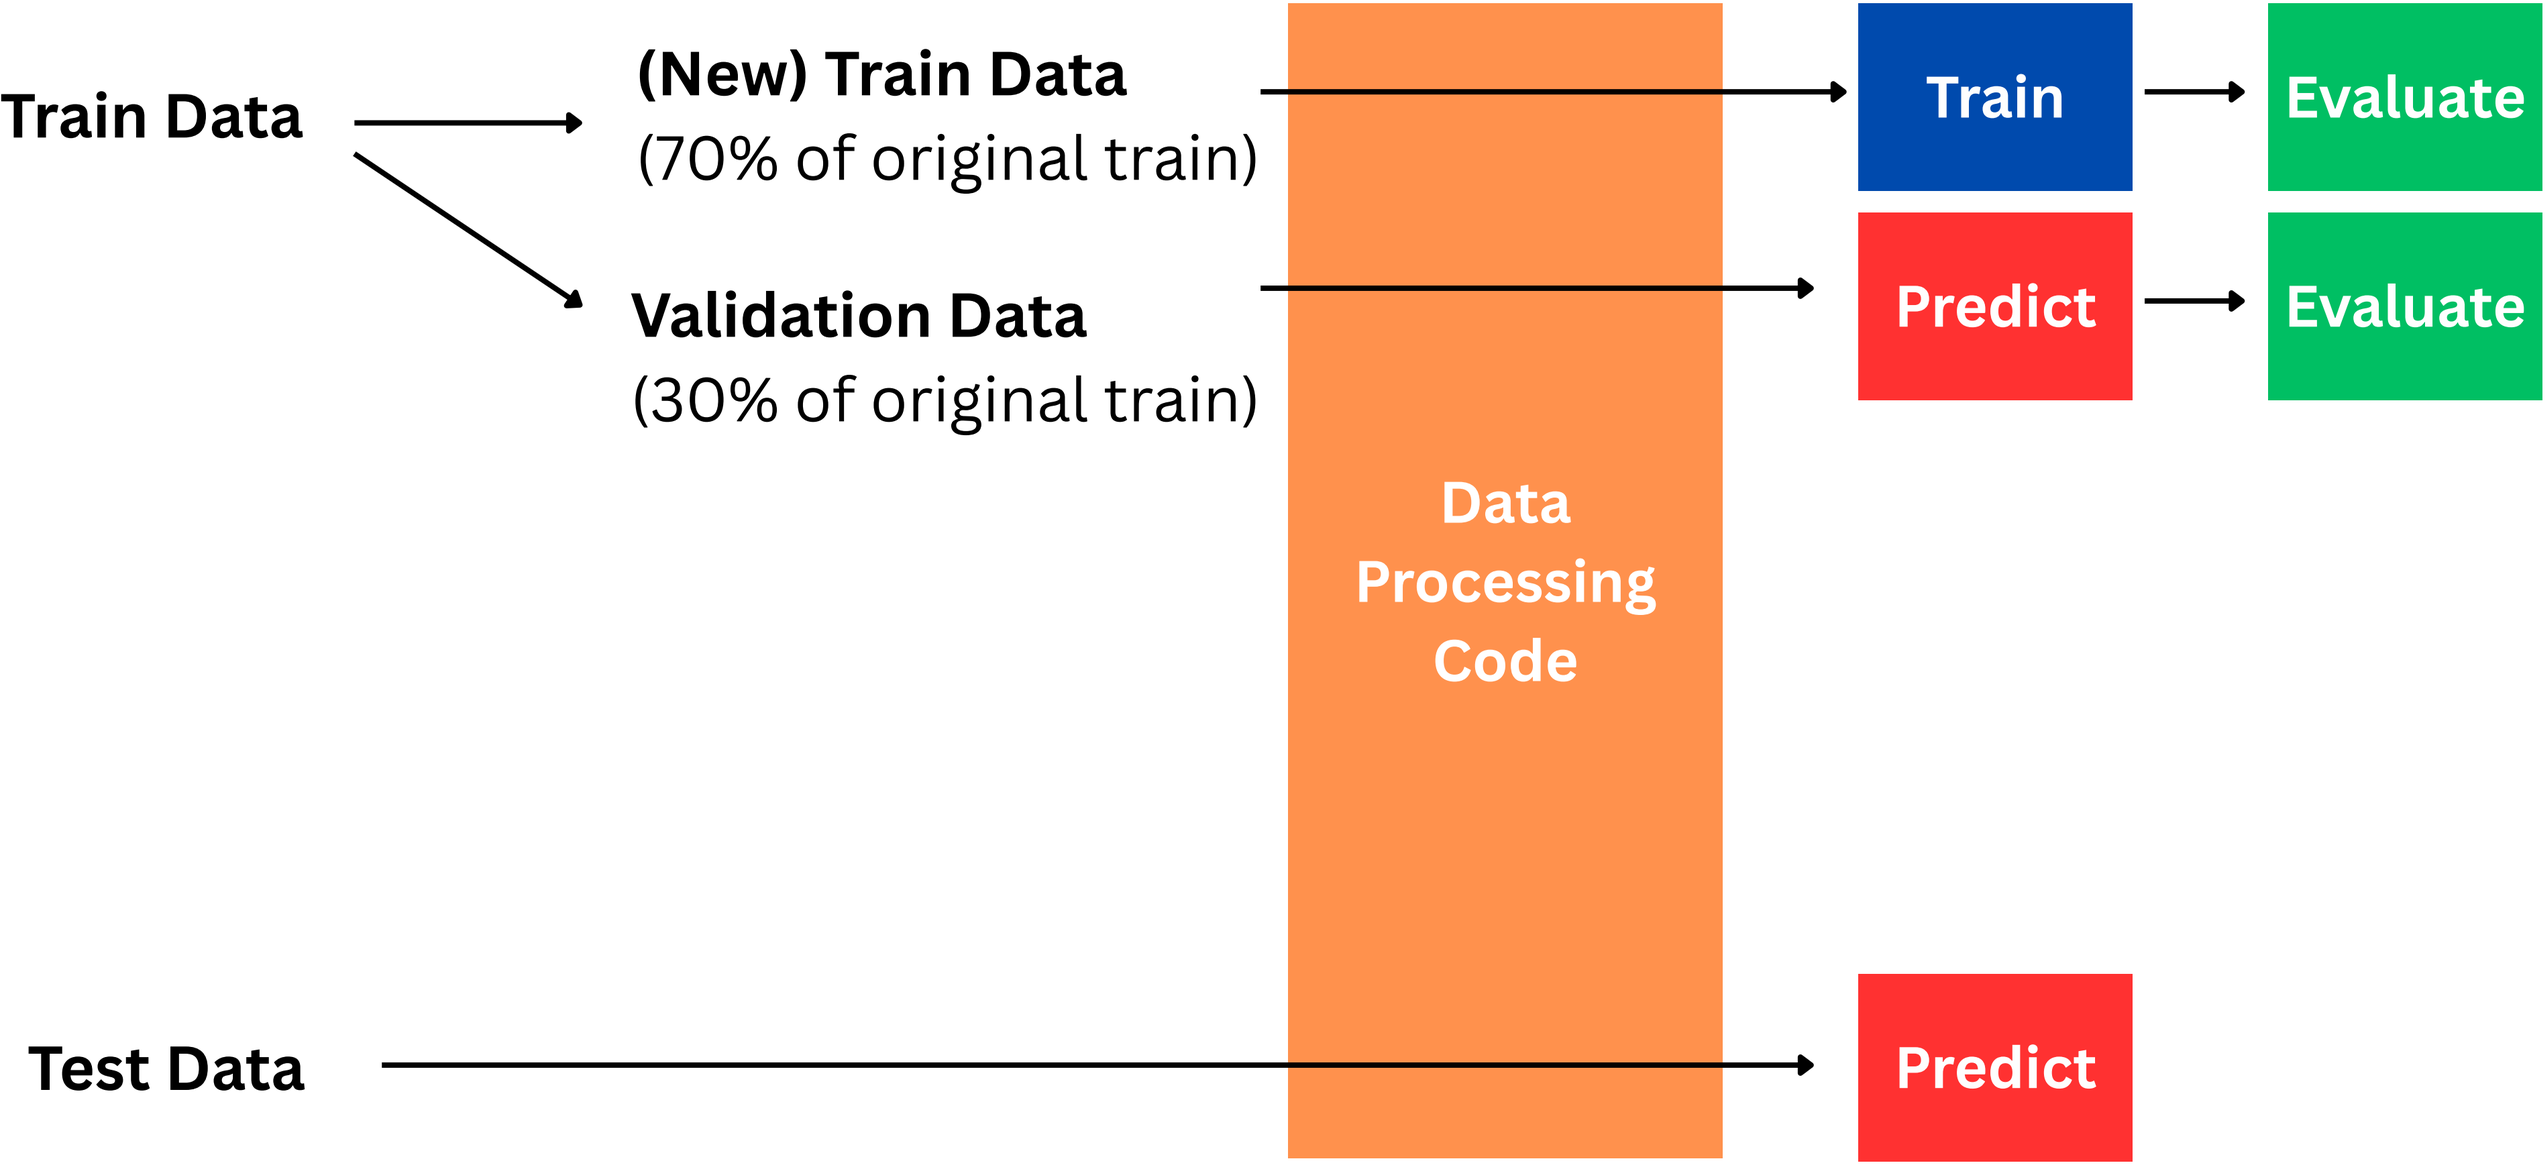

Overfitting: Ai จำข้อสอบไปตอบ (สิงห์สนามซ้อม)

(New) Train Data
(70% of original train)

Validation Data
(30% of original train)

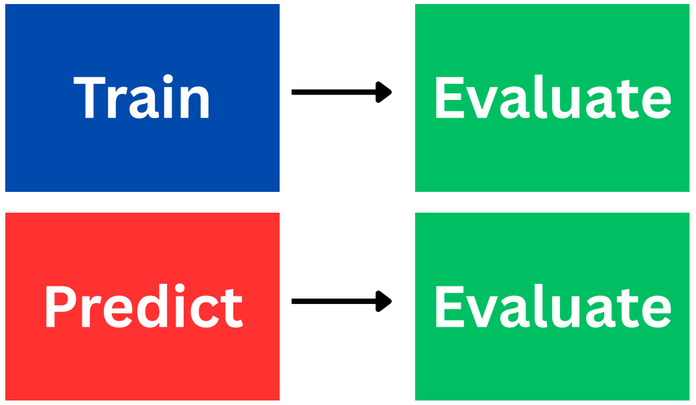

คะแนน Train

คะแนน Validation

Overfit คะแนน Train > Validation

การแก้ Overfitting

Features ⟶ (Function)-> Label

- จำนวน Features เยอะไป → Overfit
- จำนวน Examples น้อยไป → Overfit

การแก้ Overfitting

Features → (Function)-> Label

Config ของ Machine Learning Model Hyperameter

- โมเดลใหญ่ไป → Overfit
- เทรนโมเดลนานไป → Overfit

ปัญหา Imbalace Data

“จำนวนของ Class ที่เราจะ Predict มีไม่เท่ากัน”

ถ้าไม่แก้ โมเดลมีโอกาสดิ่งข้อสอบเลย เพราะดิ่ง = ได้คะแนนเกือบเต็มทันที

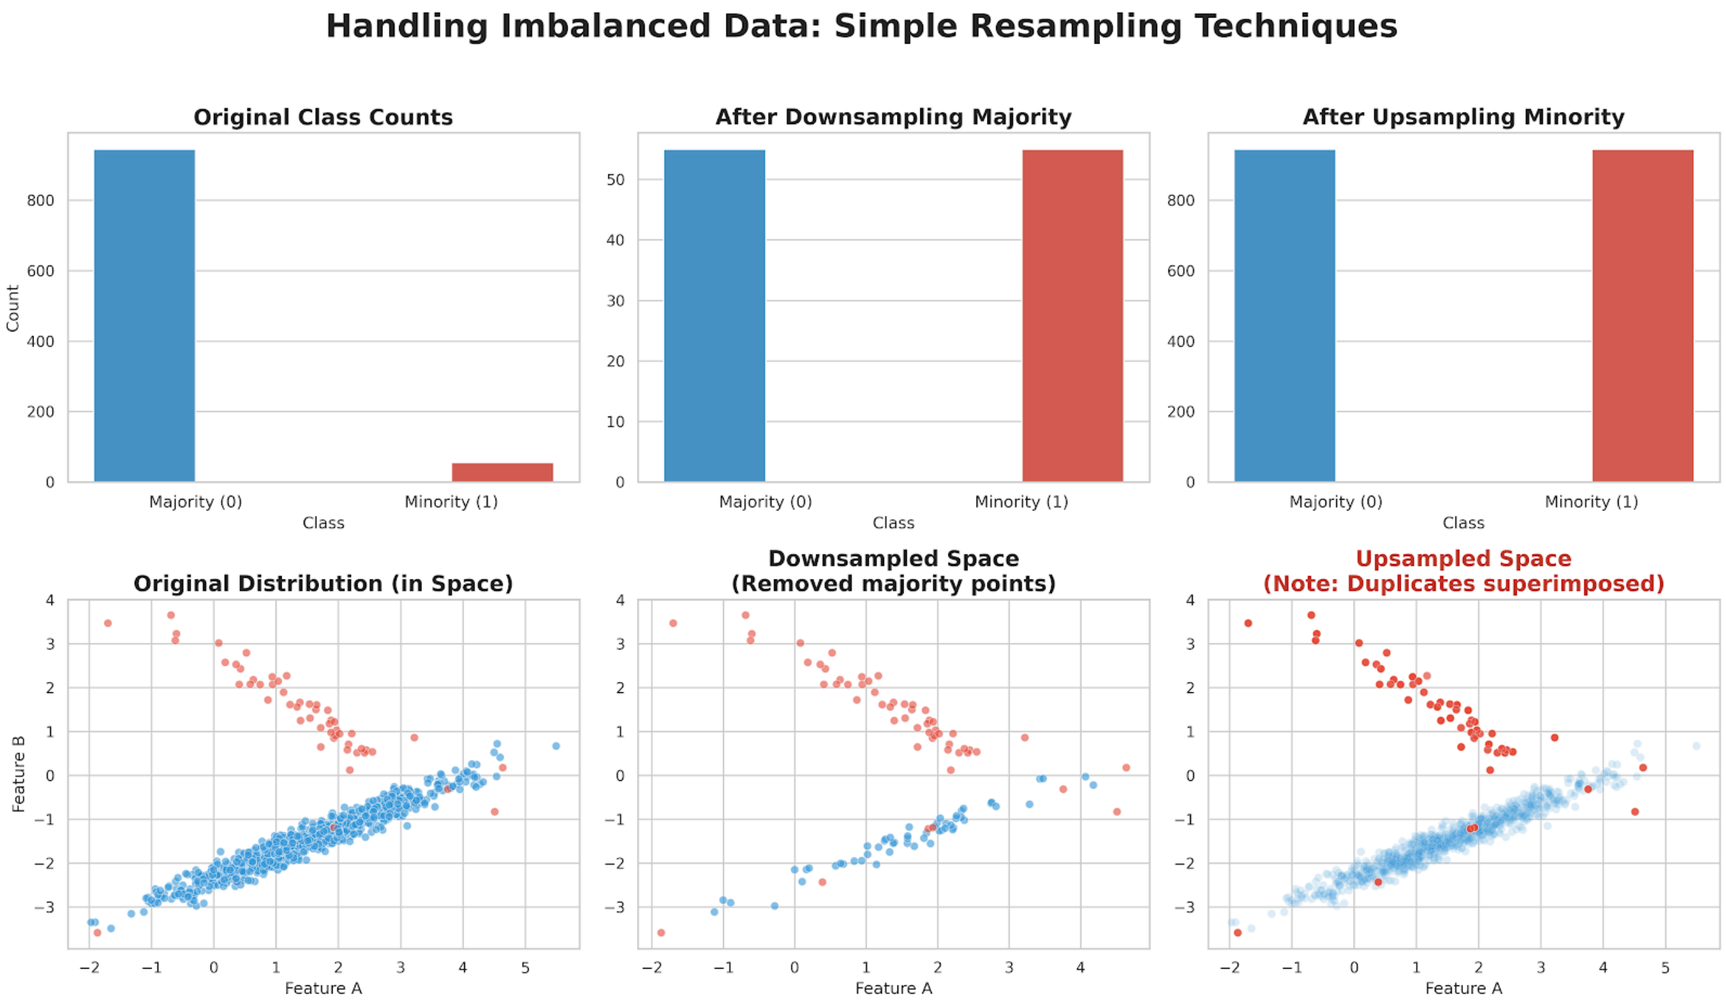

ควรใช้โมเดลไหนกับงานเรา

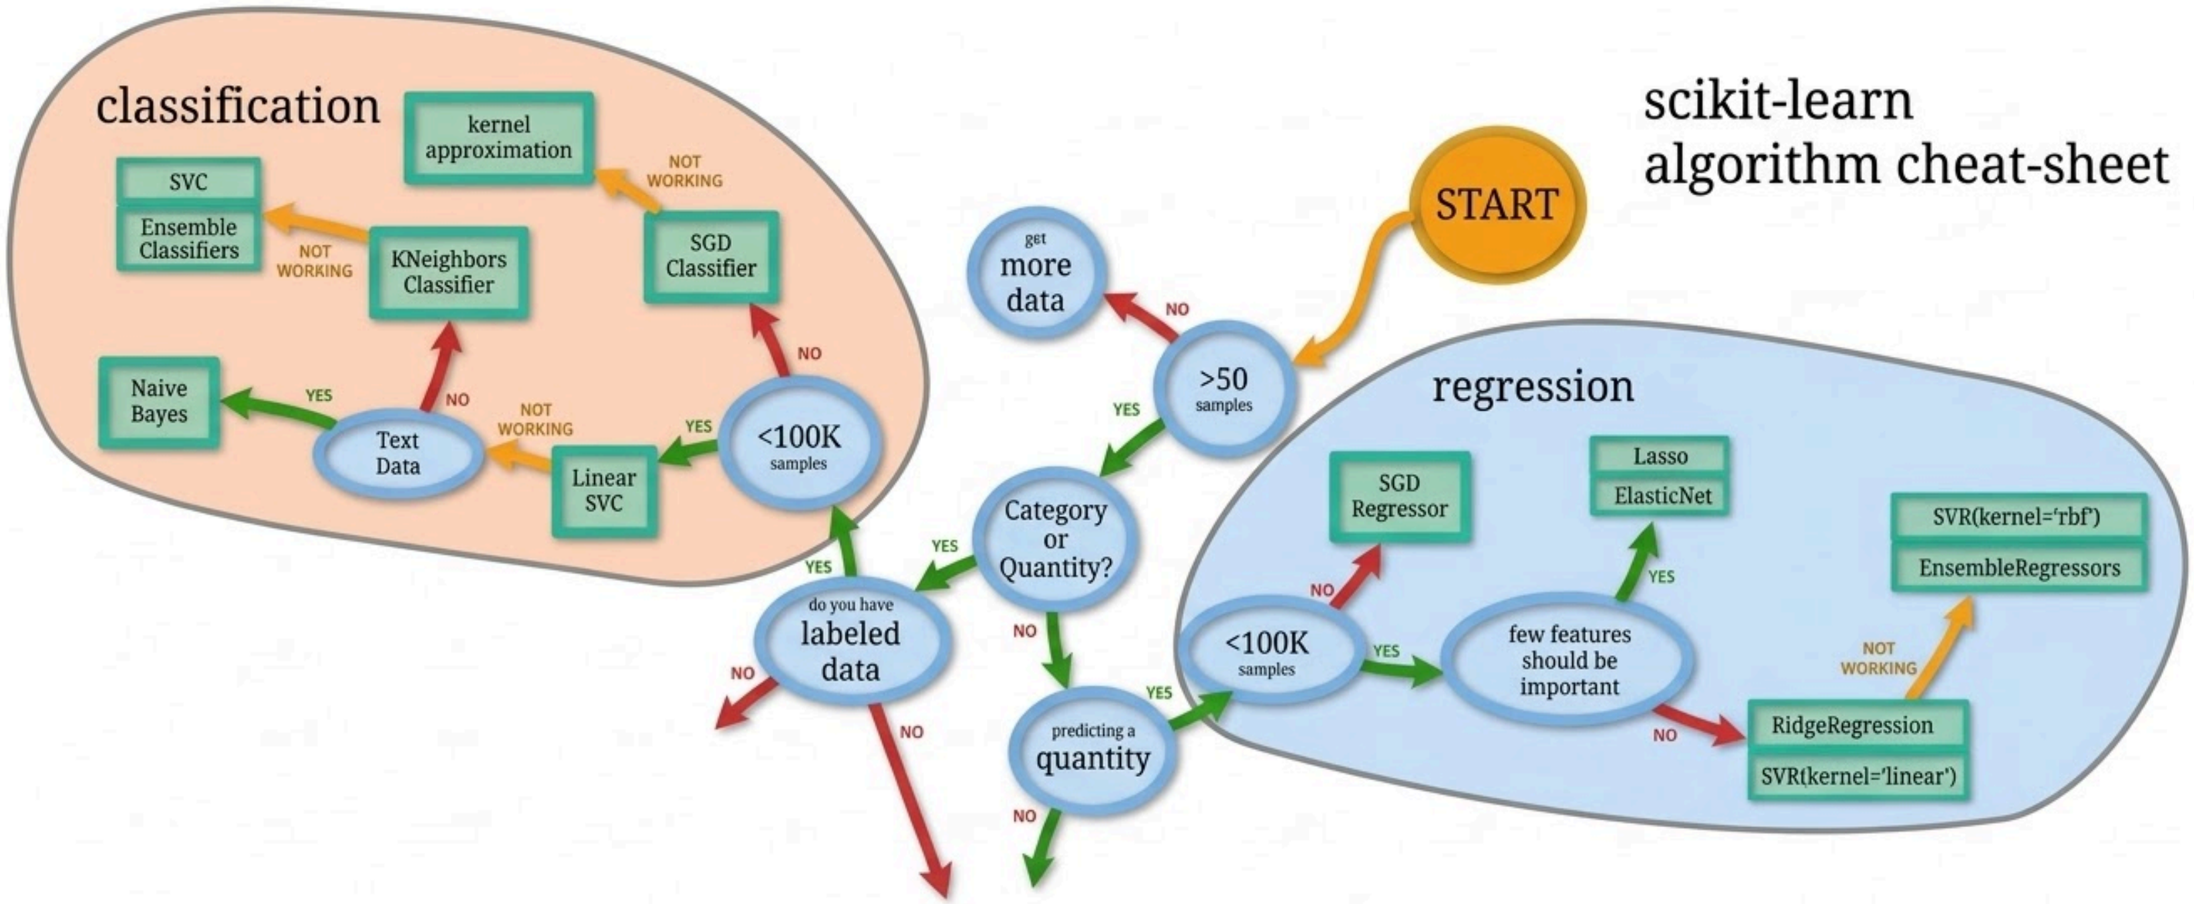

https://scikit-learn.org/1.4/tutorial/machine_learning_map/index.html

เทคนิค Ensemble

“เอาหลายโมเดลมาช่วยกัน Predict จะได้เก่งขึ้น”

แก้ปัญหาเหล่านี้ได้

- Overfitting
- Underfitting

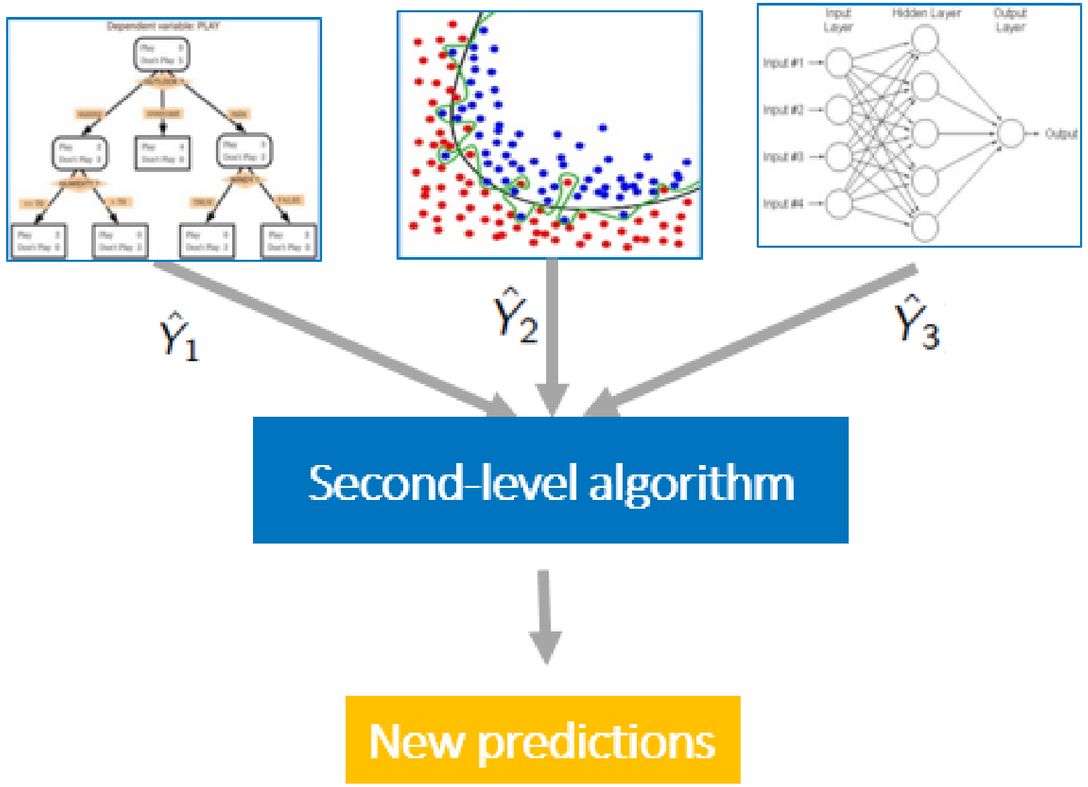

https://blogs.sas.com/content/subconsciousmusings/2017/05/18/stacked-ensemble-models-win-data-science-competitions/

การวัดผลโมเดล Classification

Precision Recall สร้างมาสู้รบกับ Imbalance Dataset”

เน้นถูกต้องไว้ก่อน ไม่ครบไม่เป็นไร

Precision

จับของมาได้ 10 ชิ้น เป็นปลาจริง 8 ชิ้น เป็นขยะ 2 ชิ้น

Precision = 8 / 10

Ex. Automated Trading system

- execute ผิดพลาด<u>เสียหายสูง</u>
- ไม่ execute <u>เสียหายต่ำ</u>

เน้นครบไว้ก่อน ผิดบ้างไม่เป็นไร

Recall

ในบ่อมีปลาทั้งหมด 100 ตัว แต่คุณจับขึ้นมาได้แค่ 8 ตัว

Recall = 8 / 100

Ex. Defect detection

- execute ผิดพลาด<u>เสียหายต่ำ</u>
- ไม่ execute <u>เสียหายมาก</u>

Before

ML Model → **Yes/No**

Actually

ML Model → **Yes: Confidence 0.84**

```
If confidence > thresold:
    label = True
else:
    label  = False
```

Precision vs Recall

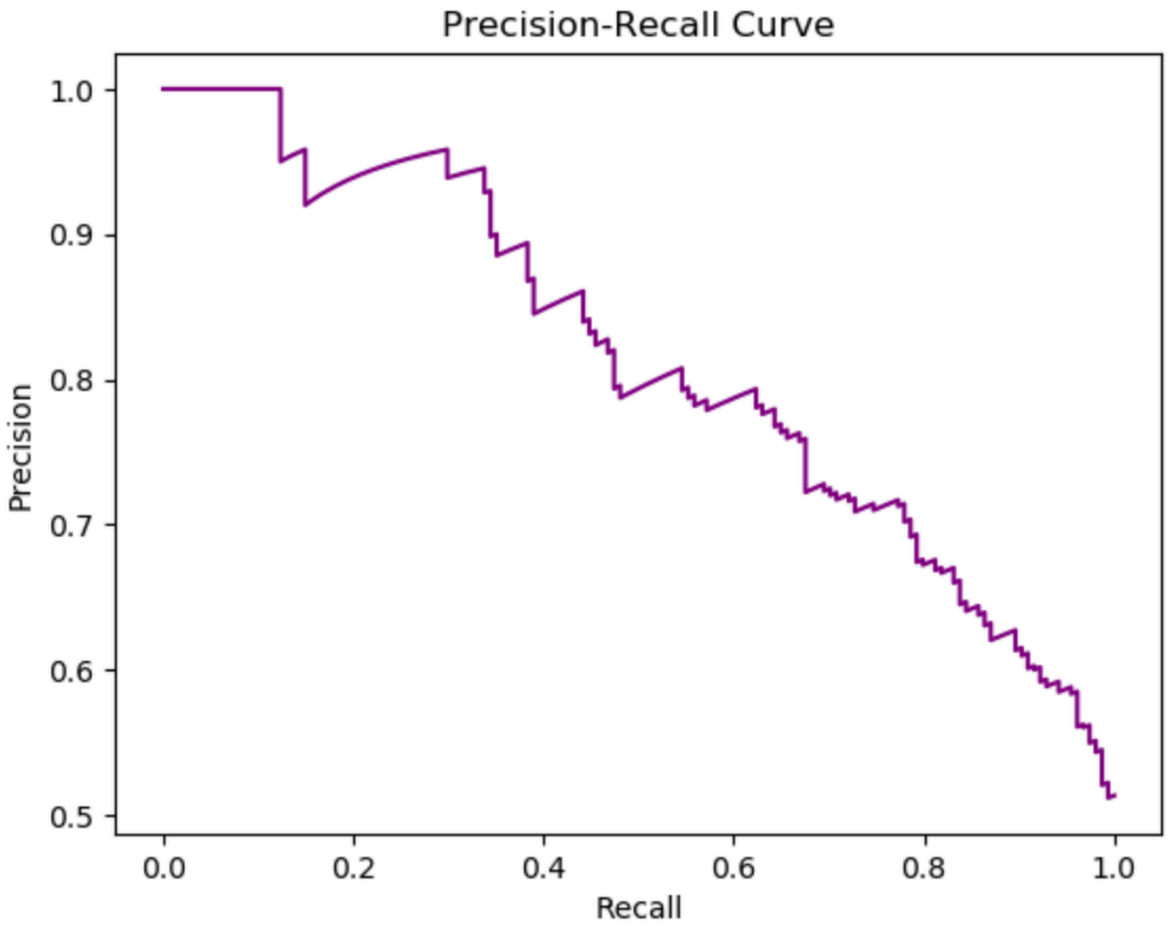

- อยากได้ถูกต้อง → precision → เพิ่ม thresold
- อยากได้ครบถ้วน → recall → ลด thresold

F1-Score

$$\text{F1 Score} = \frac{2}{\frac{1}{\text{Precision}} + \frac{1}{\text{Recall}}}$$

$$= \frac{2 \times \text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}}$$

การวัดผลโมเดล Regression

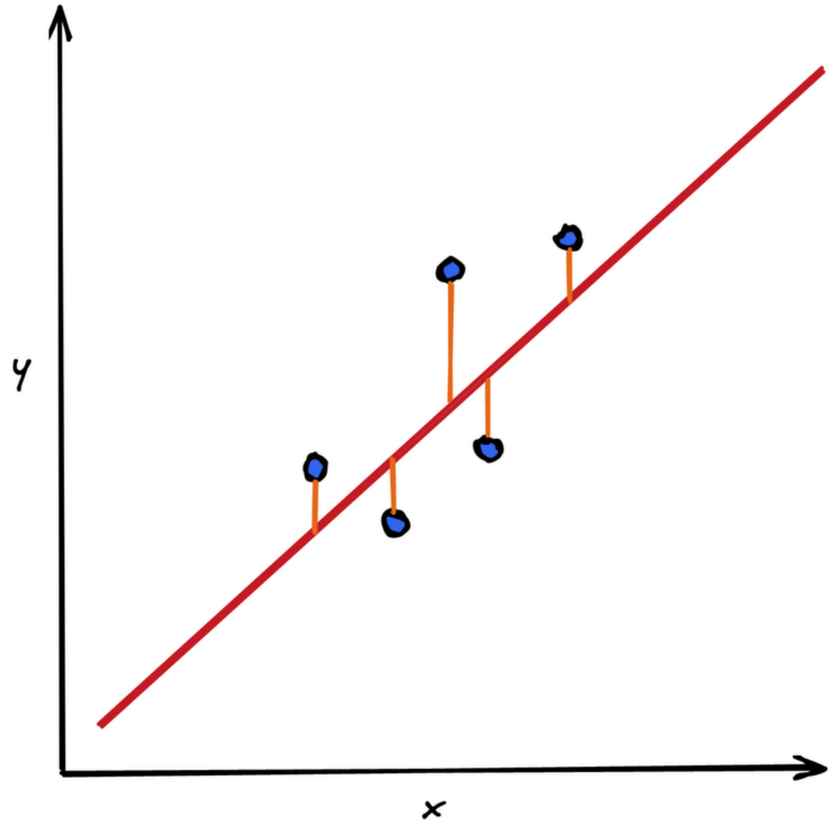

“Error Rate”

- Percent
- Average
- Absolute

...

https://developer.nvidia.com/blog/a-comprehensive-overview-of-regression-evaluation-metrics/

Hackathon Time

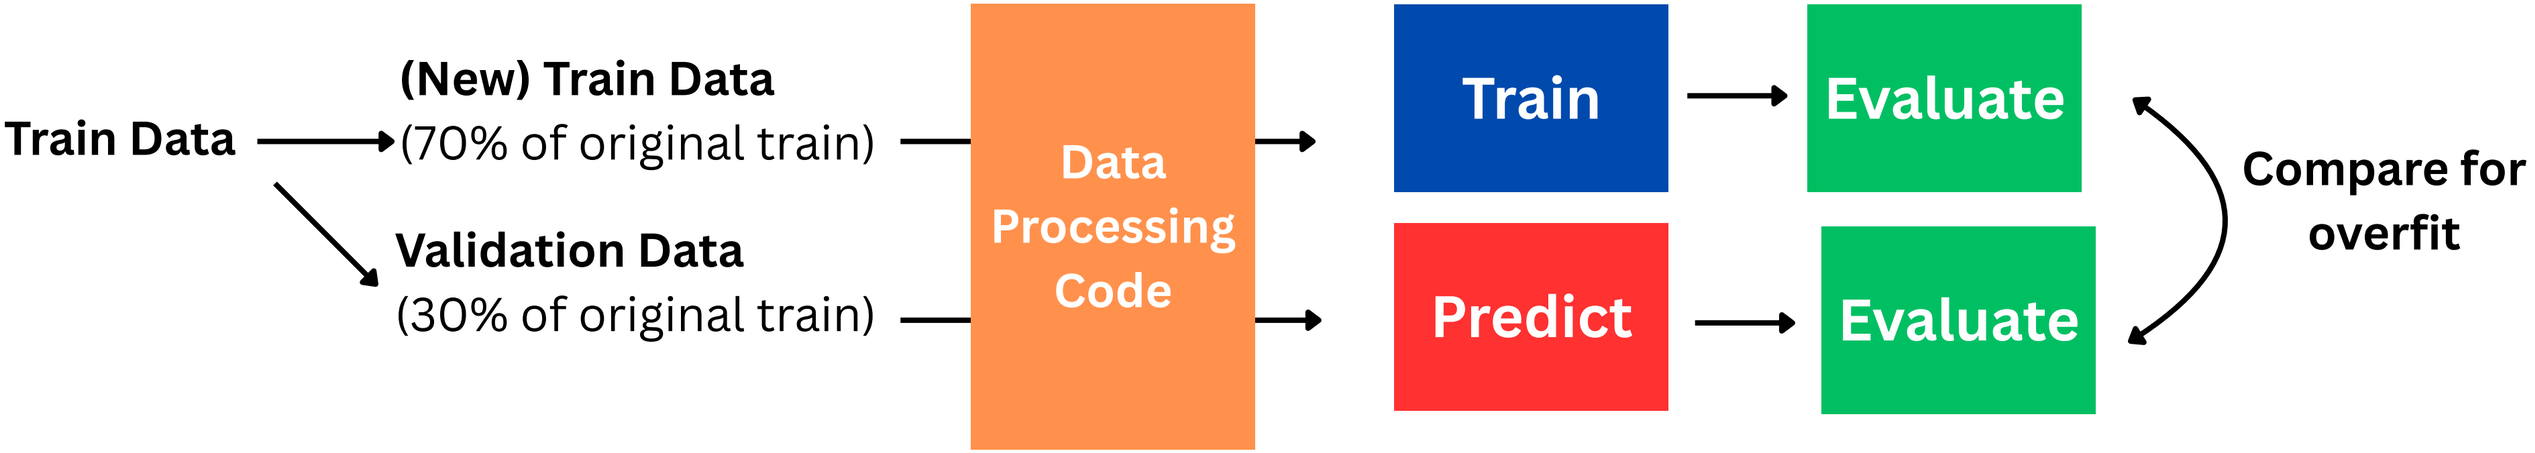

ลองให้มากที่สุด เรียงตามลำดับ

1. **Model ทุกรูปแบบ**
2. **Hyperparater หลายแบบ**
3. **Feature Selection แต่ละวิธี**
4. **Feature Engineering แต่ละแบบ**
5. **เก็บข้อมูลเพิ่ม (ชีวิตจริง)**
   a. **เพิ่มจำนวน examples**
   b. **เพิ่ม features ที่เก็บ**

"ลองจนมั่นใจแล้วค่อยมาทำตรงนี้"

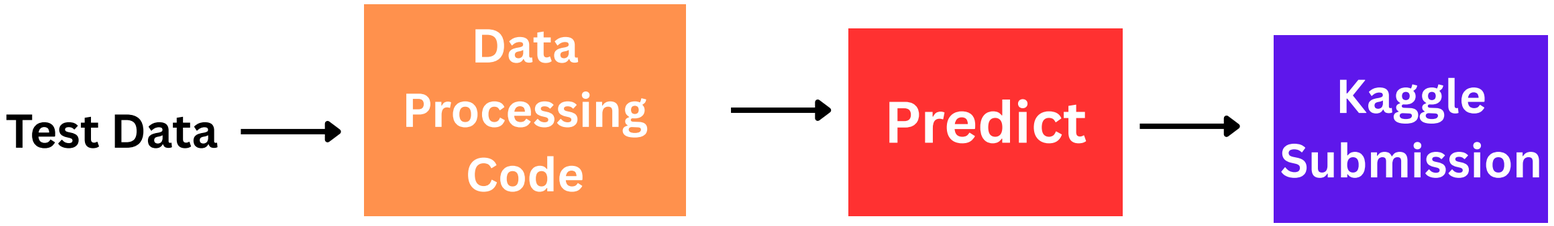

AutoML

Auto ML

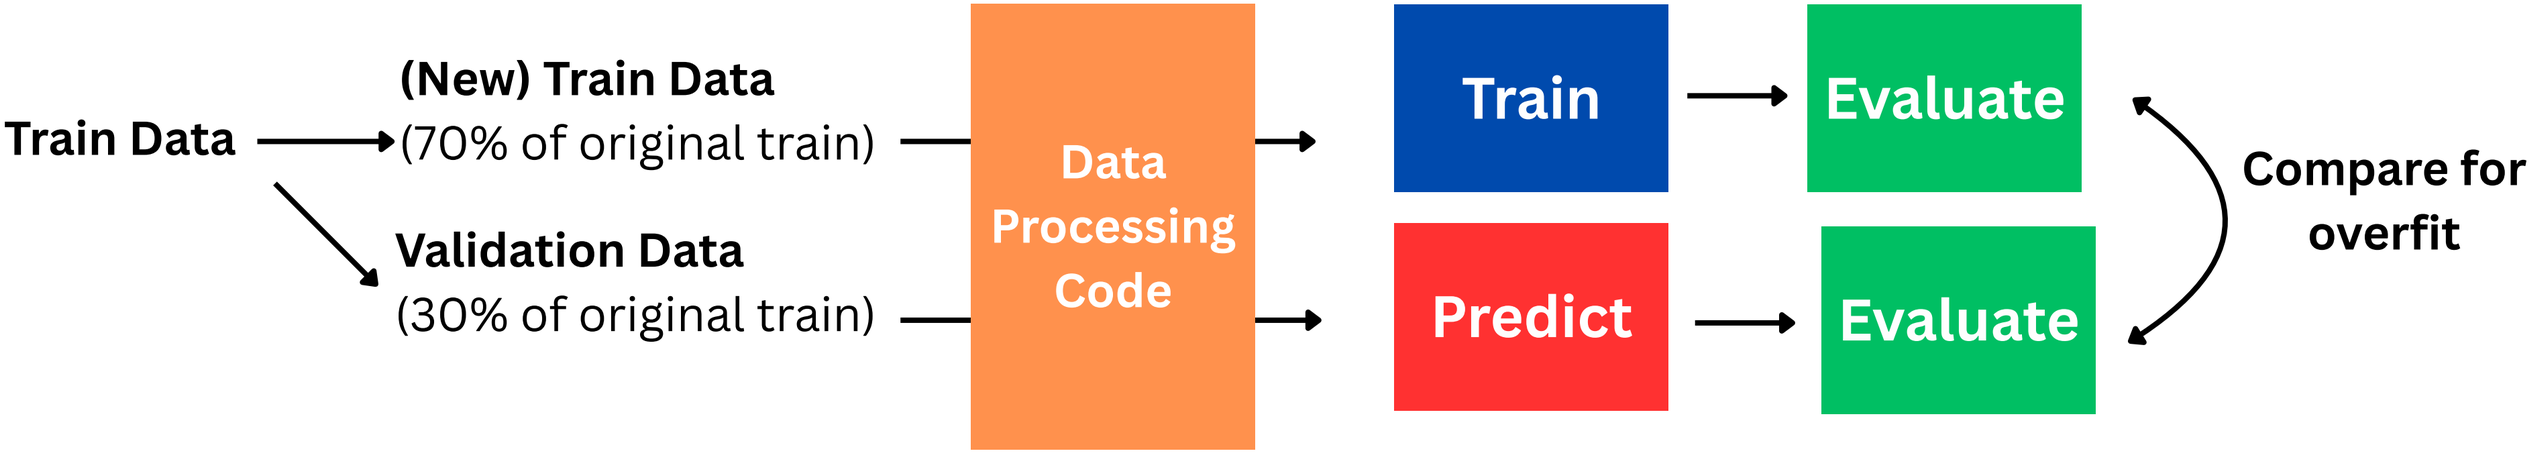

ลองให้มากที่สุด เรียงตามลำดับ

1. **Model ทุกรูปแบบ + Ensemble** ✅
2. **Hyperparater หลายแบบ** ✅
3. **Feature Selection แต่ละวิธี** ✅
4. **Feature Engineering แต่ละแบบ** ❌
5. **เก็บข้อมูลเพิ่ม (ชีวิตจริง)** ❌
   a. **เพิ่มจำนวน examples**
   b. **เพิ่ม features ที่เก็บ**

“AutoML จะไม่ลองทุกอย่าง แต่จะมี Algorithm อยู่ว่าต้องลองอะไรบ้างจาก result ของวิธีที่ลองไปแล้ว”

Auto ML Good and Bad

สิ่งที่ AutoML ทำได้ดี

- **ลอง Model ทุกรูปแบบ + Ensemble** ✅
- **ลอง Hyperparater หลายแบบ** ✅
- **ลอง Feature Selection แต่ล่ะวิธี** ✅

สิ่งที่ AutoML ทำไม่ได้ หรือได้ไม่ดี

1. **Feature Engineering แต่ล่ะแบบ** ❌
2. **แก้ Imbalance Dataset** ❌
3. **ระวัง Data Leakage** ❌
4. **เลือกวิธีวัดผลที่ตรงกับ Hackathon ต้องการ** ❌

Convert Free Text to numerical value

Sentence Transformers

```python
from sentence_transformers import SentenceTransformer

# 1. Load a pretrained Sentence Transformer model
model = SentenceTransformer("all-MiniLM-L6-v2")

# The sentences to encode
sentences = [
    "The weather is lovely today.",
    "It's so sunny outside!",
    "He drove to the stadium.",
]

# 2. Calculate embeddings by calling model.encode()
embeddings = model.encode(sentences)
print(embeddings.shape)
# [3, 384]
```

https://sbert.net

Model Choices: For Thai Text